

Identification de mesures d'évaluation fiables pour la révision de textes scientifiques

Léane Jourdan[♣], Florian Boudin[♦], Richard Dufour[♣], Nicolas Hernandez[♣]
{firstname.lastname}@univ-nantes.fr
♣ LS2N, Nantes Université ♦ JFLI, NII, Tokyo

Introduction - Contexte

Domaine

- Assistance à l'écriture scientifique

Motivations

- Écrire un article scientifique est une tâche difficile
- De bonnes compétences rédactionnelles sont indispensables
- Particulièrement pour les jeunes chercheurs et les non natifs anglophones

Tools



LinggleWrite



DeepL Write **BETA**

TRINKA
by enago

Workshops

Workshop on Innovative Use of NLP for Building Educational Applications (BEA)

Acronym: BEA
Venue ID: bea


2024	• Proceedings of the 19th Workshop on Innovative Use of NLP for Building Educational Applications (BEA 2024) 59 papers
2023	• Proceedings of the 18th Workshop on Innovative Use of NLP for Building Educational Applications (BEA 2023) 66 papers

Writing Aids at the Crossroads of
AI, Cognitive Science and NLP

Abu-Dhabi, UAE, January 20, 2025
Organizers: Zock, M., Inui, K., & Yuan, Z.


Workshop co-located with COLING
<https://coling2025.org>

ie of NLP for Building Educational Applications (BEA 2022) **32 papers**
ie of NLP for Building Educational Applications



In2Writing


Introduction - Processus d'écriture



Définition


La révision de texte est la transformation d'une portion de texte en une version améliorée selon un attribut (formalité, clarté, etc.) plus proche du texte voulu

Exemple



Introduction - Tâche

La tâche de révision de paragraphe



Habituellement évaluée en utilisant

Similarité basée sur :

- n-grammes
- plongements



BLEU
ROUGE
METEOR
SARI
GLEU
BERTScore



Entrées :

- Référence + Généré
- Original + Référence + Généré

Introduction - Jeu de données

*Jeu de test de **ParaRev**¹*

- 258 paires de paragraphes révisés
- 2 annotations/paragraphes
 - = 516 révisions à effectuer
- 5 types de révisions

Écrits par les auteurs de l'article.
Collectés sur Open Review.

Précédente tâche d'annotation
Pas l'auteur original

Original paragraph

[...] **Nevertheless, challenges exist for** developing deep learning-based models to predict mutational effects on protein-protein **binding. The major challenge is the scarcity of experimental data — only** a few **thousands of** protein **mutations** annotated with **the change** in binding **affinity** are publicly available (Geng et al., **2019b**). **This hinders** supervised learning **as the insufficiency of training data tends to cause over-fitting.** [...]

Gold revised paragraph

[...] **However,** developing deep learning-based models to predict mutational effects on protein-protein **binding is challenging due to the scarcity of experimental data. Only** a few **thousand** protein **mutations,** annotated with **changes** in binding **affinity,** are publicly available (Geng et al., **2019b**), **making** supervised learning **challenging due to the potential for overfitting with insufficient training data.** [...]

Manual Annotation

Revision Instruction

Rewrite this paragraph for better readability.

Intention label

Rewriting_medium


Performances des modèles de révision

Modèle de révision	BLEU	ROUGE-L	METEOR	GLEU	SARI	Bertscore
contrôle : aucune modification	66.00	78.30	83.80	25.78	60.63	95.95
CoEdit-XL	50.24	67.46	66.66	23.84	39.60	93.90
Mistral-7B-Instruct-v0.2	27.77	50.79	54.02	15.38	31.63	92.14
Meta-Llama-3-8B-Instruct	41.66	62.07	62.00	25.78	39.33	93.53
Meta-Llama-3-70B-Instruct	46.78	65.61	67.20	30.31	42.74	93.90
GPT4o-mini	<u>51.68</u>	<u>69.54</u>	<u>72.70</u>	32.67	<u>45.06</u>	<u>94.80</u>
GPT4o	49.34	68.20	69.88	<u>31.35</u>	43.54	94.45

Limites des métriques basées sur la similarité

1. Les métriques sont fortement corrélées, fournissant des informations redondantes
2. Elles capturent seulement la similarité de surface
3. Les révisions substantielles sont pénalisées

SARI et GLEU se démarquent, et sont les seules à considérer le texte original.



Exploration d'approches alternatives pour l'évaluation

 **Objectif** : Définir un jeu de métriques complémentaires et fiables pour évaluer la révision de paragraphes

 **1. Évaluation manuelle par paires** de révisions générées par différents modèles

3 niveaux :

1. **Suivi de l'instruction**
2. **Acceptabilité**
3. **Préférence**

 **2. Identification des métriques candidates**

Domaines connexes du TAL

Entrées : Original + Généré

BETS : Simplification de texte

BLANC : Résumé automatique

ParaPLUIE : Détection de paraphrase

GML-Juges

Entrées : Original + Généré (+ Réf)

GML-Choix : (Oui/Non + Paires)

GML-Likert : (Scores)

3. Alignement du jugement humain à l'évaluation automatique


Résultats

Juge	Exact.	V	K
Moy. GML-choix	0.496	0.239	0.247
Moy. GML-Likert	0.338	0.240	0.181
ParaPLUIE	0.477	0.225	0.197
BETS	0.437	0.152	0.127
BLANC	0.312	0.117	-0.080
Bertscore	0.395	0.161	0.034
SARI	0.416	0.184	0.071
GLEU	0.448	0.193	0.138
ROUGE-L	0.373	0.179	-0.013
<i>Aléatoire</i>	<i>0.264</i>	<i>0.027</i>	<i>-0.006</i>


Alignement des mesures automatiques aux jugements humains

Performance par aspect

Par difficulté



Par catégorie de révision



Proposition d'évaluation alternative

1. **Suivi de l'instruction** : GML-Juge
2. **Similarité à la référence** : SARI ou GLEU
3. **Préservation du sens** : ParaPLUIE

Conclusion

Contributions


- Les métriques de similarité traditionnelles seules **échouent à évaluer avec fiabilité** la révision de texte
- Une **méthode d'évaluation alternative** composée de 3 métriques complémentaires
- **ParaReval, un jeu de données** d'évaluations humaines des paires de révisions générées

Perspectives

- GML-juge: Utiliser la **perplexité** plutôt que la sortie
- **Généralisation des résultats** aux autres tâches de génération

Contact: leane.jourdan@univ-nantes.fr

Papier :



Annexe: Exemple

